1 Projet : attaque cryptographique par MCMC

Ce sujet est inspiré de l'article scientifique suivant :

Jian Chen & Jeffrey S. Rosenthal, *Decrypting classical cipher text using Markov chain Monte Carlo*, Statistics and Computing (Springer, avril 2011).

Septembre et octobre 2026 — travail seul ou en binôme — langage au choix.

1.1 Préparation des outils théoriques et pratiques

- Révisez les chiffrements de César et Vigenère (R3.9), et les chaînes de Markov (R4.A.12).
- Retrouvez (ou refaites) les programmes développés en 2e année sur ces sujets.
- Développez des outils pour pouvoir facilement lancer la chaîne de traitements suivante : récupérer une page Wikipedia en français, convertir son contenu en texte brut avec seulement 27 caractères de référence (lettres A,...,Z et "espace"), calculer des statistiques simples (combien de fois chaque caractère, total...).

1.2 Chaîne de Markov simple pour modéliser les mots

Développez des outils pour pouvoir facilement :

- établir les statistiques des "digrammes" c'est-à-dire les groupes de 2 caractères consécutifs ;
- construire une matrice de transitions de taille 27×27 remplie avec les fréquences de passage d'un caractère au suivant (prévoir un texte source assez long...), attention à bien respecter la propriété de la somme sur chaque ligne ;
- utiliser cette matrice pour générer aléatoirement du texte, initialisé par "espace" (commenter qualitativement les productions observées).

Faites des essais avec plusieurs pages sources.

Cette chaîne de Markov est-elle irréductible ? apériodique ? Quelle(s) loi(s) stables(s) ?

Extension possible : appliquez les mêmes outils sur une page dans une autre langue.

1.3 Substitution de lettres : chiffrement, déchiffrement

Dans cette partie on utilise une clé de chiffrement mono-alphabétique parmi toutes les permutations possibles des 26 lettres ("espace" est conservé tel quel).

Exemple de représentation pour une clé :

lettre claire	A	B	C	...	X	Y	Z
lettre chiffrée	J	B	M	...	I	U	T

Développez des outils pour pouvoir facilement :

- définir et vérifier une clé de chiffrement ;
- appliquer cette clé à un texte clair pour obtenir un cryptogramme ;
- construire l'inverse de cette clé quand elle est connue ;
- déchiffrer un texte chiffré avec une clé connue.

Liens avec le chiffre de César ? Développez une attaque fréquentielle.

Extension possible : traiter "espace" comme un caractère lui aussi sujet et objet des substitutions.

1.4 Permutation de positions : chiffrement, déchiffrement

Dans cette partie on ne modifie aucune lettre du texte clair mais on les déplace. La clé de chiffrement est un bloc de longueur fixe (qu'on dupliquera autant que nécessaire, un peu comme dans le chiffre de Vigenère), qui décrit la correspondance entre les positions de départ et d'arrivée dans le bloc.

Exemple de chiffrement avec la clé 3021 :

texte clair	B	O	N	J	O	U	R	
position initiale	0	1	2	3	0	1	2	3
nouvelle position	3	0	2	1	3	0	2	1
cryptogramme	O	J	N	B	U		R	O

"BONJOUR" est donc chiffré en "OJNBU RO".

Développez des outils pour pouvoir facilement :

- définir et vérifier une clé de chiffrement ;
- appliquer cette clé à un texte clair pour obtenir un cryptogramme ;
- construire l'inverse de cette clé quand elle est connue ;
- déchiffrer un texte chiffré avec une clé connue.

Pourquoi est-ce plus difficile à attaquer ?

1.5 Décryptage : attaque par MCMC (Markov chain Monte Carlo)

L'idée est de définir une chaîne de Markov dont les états sont les clés possibles (il y en a donc beaucoup !) et dont la loi stable ait théoriquement ses plus fortes probabilités sur les clés les plus "crédibles". Si on arrive à garantir cela (et la convergence), en laissant la séquence faire de nombreuses transitions elle devrait visiter assez souvent une petite famille de clés, parmi lesquelles un humain pourra choisir rapidement.

On définit pour cela une fonction "score" qui prend en entrée une clé-hypothèse k, et se sert des statistiques sur le texte obtenu en déchiffrant avec cette clé :

$$S(k) = \prod_{(x,y)} r(x,y)^{f_k(x,y)} \quad \text{avec} \quad \begin{cases} (x,y) = \text{couple de caractères parcourant les } 27^2 \text{ possibles,} \\ r(x,y) = 1 + \text{nombre de bigrammes } xy \text{ dans un texte référence,} \\ f_k(x,y) = 1 + \text{nombre de bigrammes } xy \text{ dans le texte déchiffré.} \end{cases}$$

Pourquoi peut-on interpréter cela comme une "crédibilité" pour la clé-hypothèse k ?

Voici la structure générale de l'algorithme MCMC proposé. On initialise avec une clé quelconque (ou une "à priori intéressante") puis le mécanisme de transition se décompose en deux étapes :

- Mutation : on effectue une petite modification sur la clé actuelle k, autrement dit on propose un état k' "voisin" de l'état actuel.
- Sélection : on calcule le score $S(k')$ de la nouvelle clé,
  et on tire au sort U uniforme continue dans $]0;1[$ (indépendante de tout le reste)
  $\begin{cases} \text{si } U < S(k')/S(k) & \text{on accepte d'aller dans l'état } k'; \\ \text{sinon} & \text{on refuse c'est-à-dire qu'on reste dans l'état } k. \end{cases}$

Implémentez une version de cet algorithme pour la substitution de lettres (partie 1.4), et une version pour la permutation de positions (partie 1.4) :

- Pour les lettres, on mute par transposition dans la clé (échange de seulement deux lettres chiffrées prises au hasard).
- Pour les positions, on fixe d'abord ℓ la longueur de la clé et on mute en déplaçant un sous-bloc (exemple en cours) ; l'algorithme donne des propositions de clés pour la longueur ℓ testée.
  On essaie avec $\ell = 2$, puis $\ell = 3$, etc. et l'humain choisit entre toutes les propositions.

Pourquoi cette chaîne de Markov est-elle irréductible et apériodique ?